1. 项目介绍

1.1 项目背景

本次项目使用爬虫程序从天气网站上获取全国各省、市、区县近几年的天气数据（本项目以北京市历史数据为例：http://www.tianqihoubao.com/lishi/index.htm），然后对数据进行实时分发、收集和统计分析（例如统计某个区县近几年各类天气情况的分布或者了解某年某月哪个地区温度最高），来引导用户熟悉华为云的 MRS 服务的使用，最后通过 BI 工具进行图表展示。

1.2 数据介绍

部分数据展示如图，其中每行数据代表一次天气记录。

地区ID	省	市	地区	时间	天气	最高温度	最低温度	风力
yanqing	北京	北京	延庆	2017/6/1	晴 /阵雨	29	13	南风 3-4级 /东风 ≤3级
yanqing	北京	北京	延庆	2017/6/2	阴 /多云	21	10	东风 3-4级 /北风 ≤3级
yanqing	北京	北京	延庆	2017/6/3	晴 /晴	25	13	南风 3-4级 /北风 ≤3级
yanqing	北京	北京	延庆	2017/6/4	晴 /多云	28	15	西南风 3-4级 /北风 ≤3级
yanqing	北京	北京	延庆	2017/6/5	多云 /小雨	26	12	南风 3-4级 /北风 ≤3级
yanqing	北京	北京	延庆	2017/6/6	小雨 /多云	17	11	南风 ≤3级 /西北风 ≤3级
yanqing	北京	北京	延庆	2017/6/7	多云 /多云	28	14	南风 ≤3级 /南风 ≤3级
yanqing	北京	北京	延庆	2017/6/8	阵雨 /晴	32	17	南风 ≤3级 /北风 ≤3级
yanqing	北京	北京	延庆	2017/6/9	晴 /多云	34	17	南风 3-4级 /南风 ≤3级
yanqing	北京	北京	延庆	2017/6/10	多云 /阵雨	27	14	东南风 ≤3级 /北风 ≤3级
yanqing	北京	北京	延庆	2017/6/11	阵雨 /阵雨	29	14	南风 ≤3级 /东风 ≤3级
yanqing	北京	北京	延庆	2017/6/12	阵雨 /阵雨	24	14	南风 ≤3级 /北风 ≤3级
yanqing	北京	北京	延庆	2017/6/13	雷阵雨 /晴	26	13	南风 ≤3级 /北风 ≤3级
yanqing	北京	北京	延庆	2017/6/14	晴 /晴	34	17	南风 ≤3级 /北风 ≤3级
yanqing	北京	北京	延庆	2017/6/15	晴 /晴	35	20	南风 ≤3级 /北风 ≤3级
yanqing	北京	北京	延庆	2017/6/16	多云 /阴	35	20	东南风 3-4级 /东南风 3-4级

数据名称和对应的变量名

地区ID	省	市	地区	时间	天气	最高温度	最低温度	风力
id	province	city	zone	time	weather	maxTemperature	minTemperature	windPower

1.3 结果展示

最终可以在 BI 工具 superset 中对数据进行各种统计分析和图表展示。

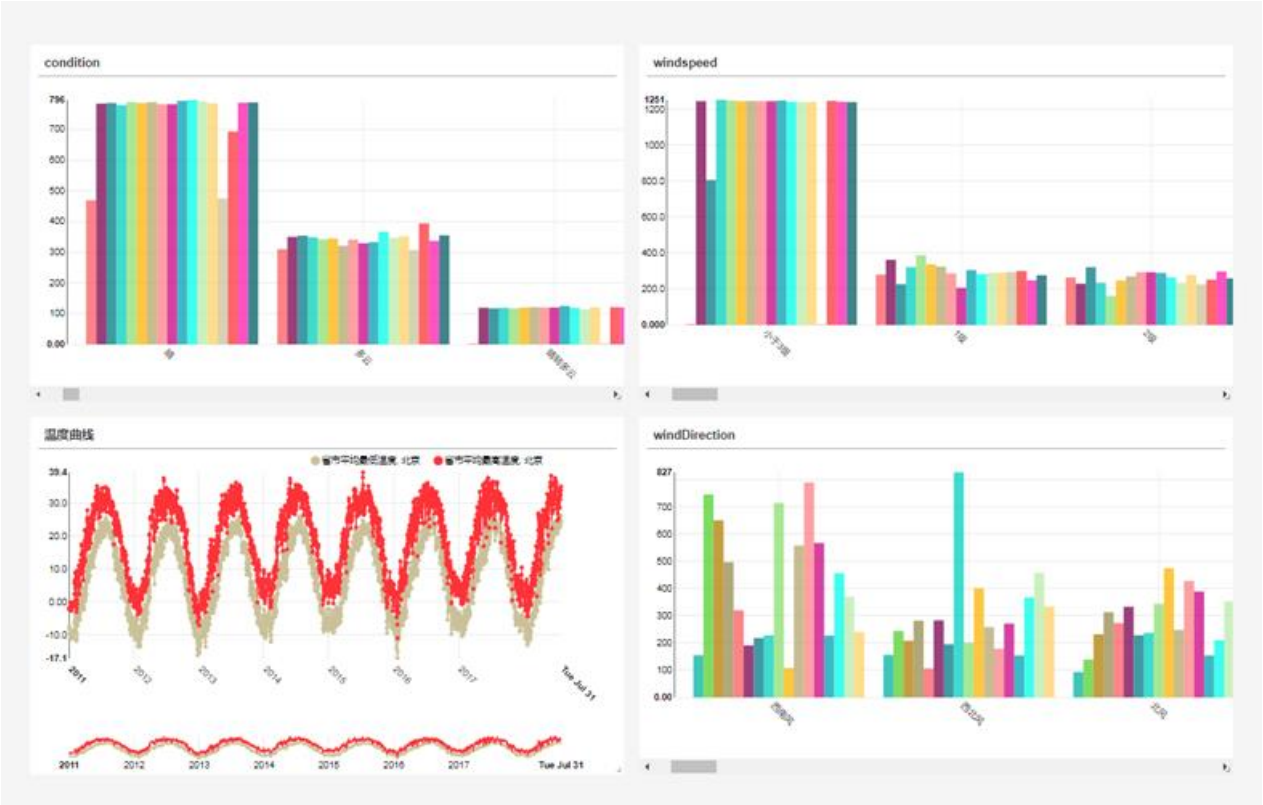

2. 解决方案流程介绍

2.1 总体执行流程

- 首先需要构建 HBase 表。
- 从网页上爬取数据。
- 使用 kafka 对数据进行分发。
- 利用 Flume 收集数据并将其写入 HBase 表。
- 构建 Hive 表并与 HBase 表进行关联。
- 使用 Superset 统计和展示 Hive 表中的数据。

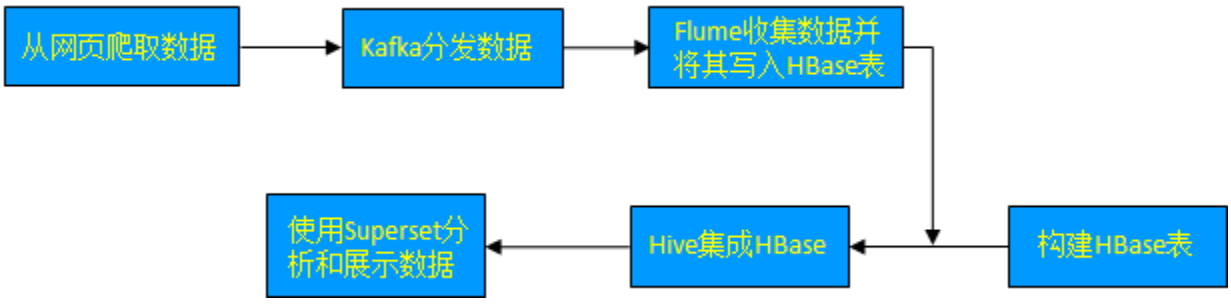

3. 创建 MRS 分析集群

3.1 申请虚拟私有云（已有虚拟私有云可跳过本步骤）

3.1.1 登录华为云控制台，选择“网络>虚拟私有云”，确认左上角的区域选择为“华北-北京一”。

3.1.2 在页面右上角中选择“创建虚拟私有云”。

3.1.3 在新打开的页面中填写虚拟私有云的基本信息，按照以下方式填写：

参数	值
区域	华北-北京一
名称	vpc-mrs-demo
网段	默认值
标签	默认值
可用区	可用区 2
子网名称	subnet-mrs-demo

子网网段	默认值
高级配置	默认配置

配置完成以后如下图所示

3.1.4 检查当前配置后单击“立即创建”。

3.2 购买 MRS 分析集群（已购买分析集群可跳过此步骤）

3.2.1 登录华为云控制台，选择“EI 企业智能 > MapReduce 服务”。

3.2.2 在页面中选择“购买集群”，进入“集群配置”页面。

3.2.3 在新打开的页面中填写集群的基本信息（“集群高可用”和“集群节点”配置在本次实践将采用低成本配置）：

参数	值
计费模式	按需计费
当前区域	默认值：华北-北京一
可用分区	默认值：可用区 2
集群名称	mrs_demo_analysis
集群版本	1.7.2

Kerberos 认证	默认值：关闭
集群类型	默认值：分析集群
组件选择	全选
虚拟私有云	选择之前创建的 VPC：vpc-mrs-demo
子网	选择之前创建 VPC 对应的子网：sunbet-mrs-demo
安全组	默认值：自动创建
集群高可用	关闭
集群节点	Master 的实例规格：通用计算增强型 C3 4 核 16GB
	Core 的实例规格：通用计算增强型 C3 4 核 16GB
	Core 的实例数量：1
登录方式	默认值：密码
高级配置	暂不配置

注意：如果集群节点的规格置售罄请按照如下方法尝试：

1. **优先切换可用区，查看其它可用区该规格是否仍有资源**
2. **如果其它可用区没有 C3 规格，请选择 S3 4 核 16GB 规格。**

配置完成以后部分信息如下图所示，最终费用为 3.31 元/小时即代表配置正确：

3.2.4 配置后点击“立即购买”进行集群的创建。等到集群创建成功后，点到集群管理界面中可以看到集群的完成状态。

4. 创建 MRS 流式集群并安装 Superset

4.1 购买 MRS 流式集群并配置 Superset

4.1.1 登录华为云控制台，选择“EI 企业智能 > MapReduce 服务”。

4.1.2 在页面中选择“购买集群”，进入“集群配置”页面。

4.1.3 在新打开的页面中填写集群的基本信息（“集群高可用”和“集群节点”配置在本次实践将采用低成本配置）：

参数	值

计费模式	按需计费
当前区域	默认值：北京一
可用分区	默认值：可用区 2
集群名称	mrs_demo_stream
集群版本	1.7.2
Kerberos 认证	默认值：关闭
集群类型	默认值：流式集群
组件选择	全选
虚拟私有云	选择之前创建的 VPC：vpc-mrs-demo
子网	选择之前创建 VPC 对应的子网：sunbet-mrs-demo
安全组	需选择分析集群创建的安全组
集群高可用	关闭
集群节点	Master 的实例规格：通用计算增强型 C3 4 核 16GB
	Core 的实例规格：通用计算增强型 C3 4 核 16GB
	Core 的实例数量：1
登录方式	默认值：密码
高级配置	现在配置
引导操作	现在添加，详情看 4.1.4

注意：如果集群节点的规格置售罄请按照如下方法尝试：

1. **优先切换可用区，查看其它可用区该规格是否仍有资源**
2. **如果其它可用区没有 C3 规格，请选择 S3 4 核 16GB 规格。**

配置完成以后部分信息如下图所示，最终费用为 3.31 元/小时即代表配置正确：

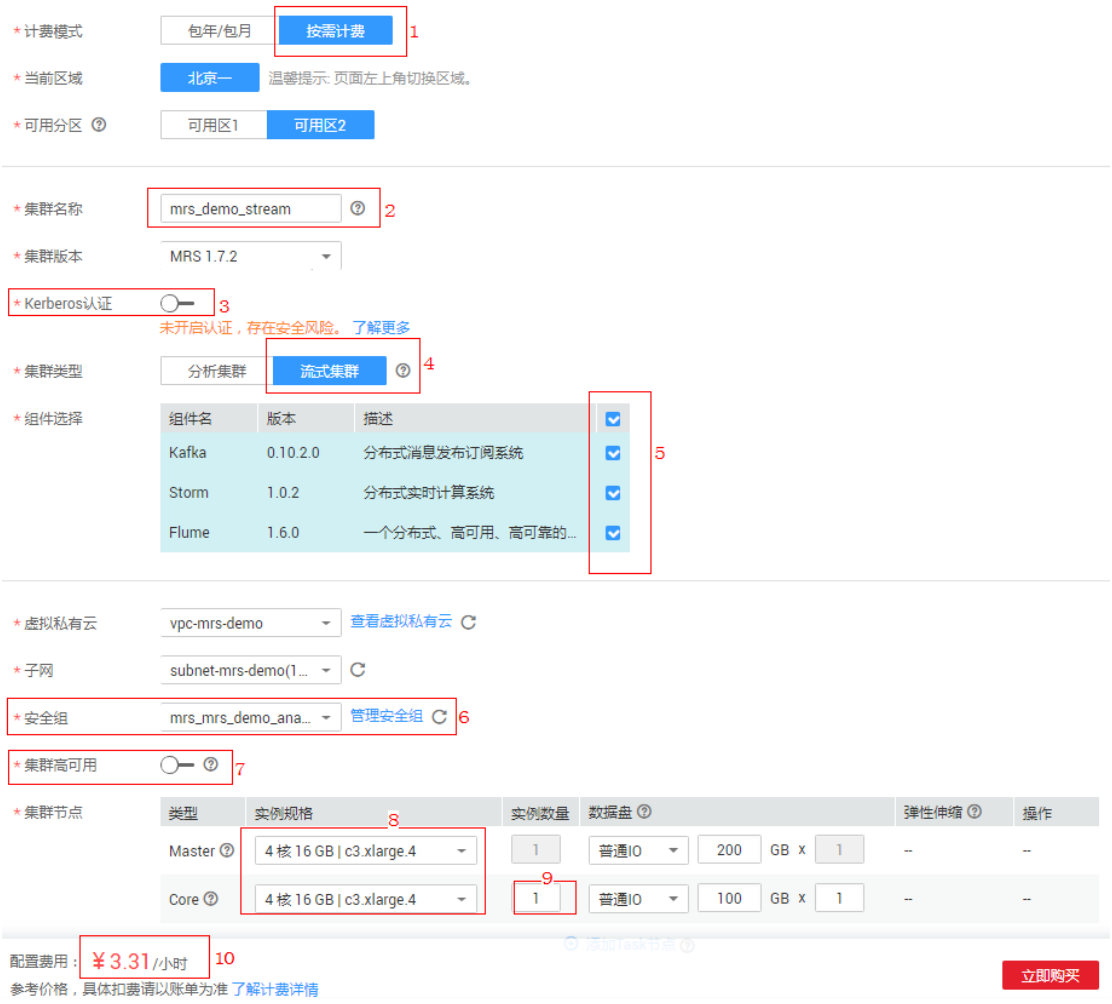

4.1.4 将“高级配置”设置成“现在配置”，然后在“引导操作”内点击“添加”按钮。

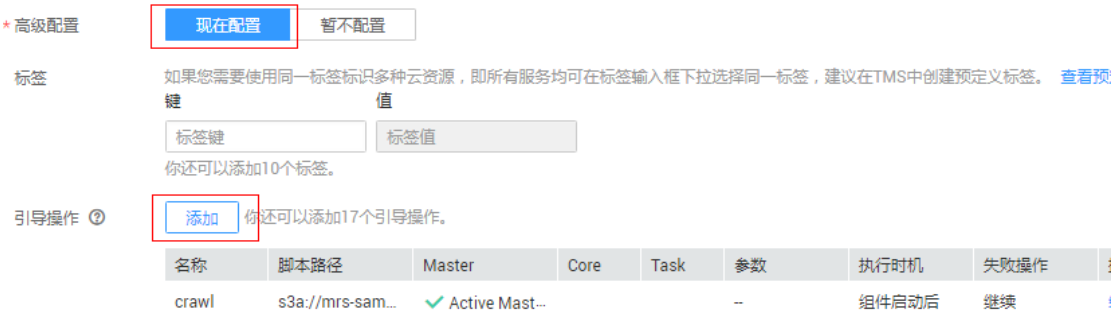

4.1.5 引导操作的内容如下：

参数	值
名称	crawl
脚本路径	s3a://mrs-samples-bootstrap-cn-north-1/superset/superset_install.sh（华北区） s3a://mrs-samples-bootstrap-cn-east-2/superset/superset_install.sh（华东区） s3a://mrs-samples-bootstrap-cn-south-1/superset/superset_install.sh（华南区）
执行节点	Master 将 Active Master 按钮打开。
参数	默认值：（空）
执行时机	默认值：组件启动后
失败操作	继续

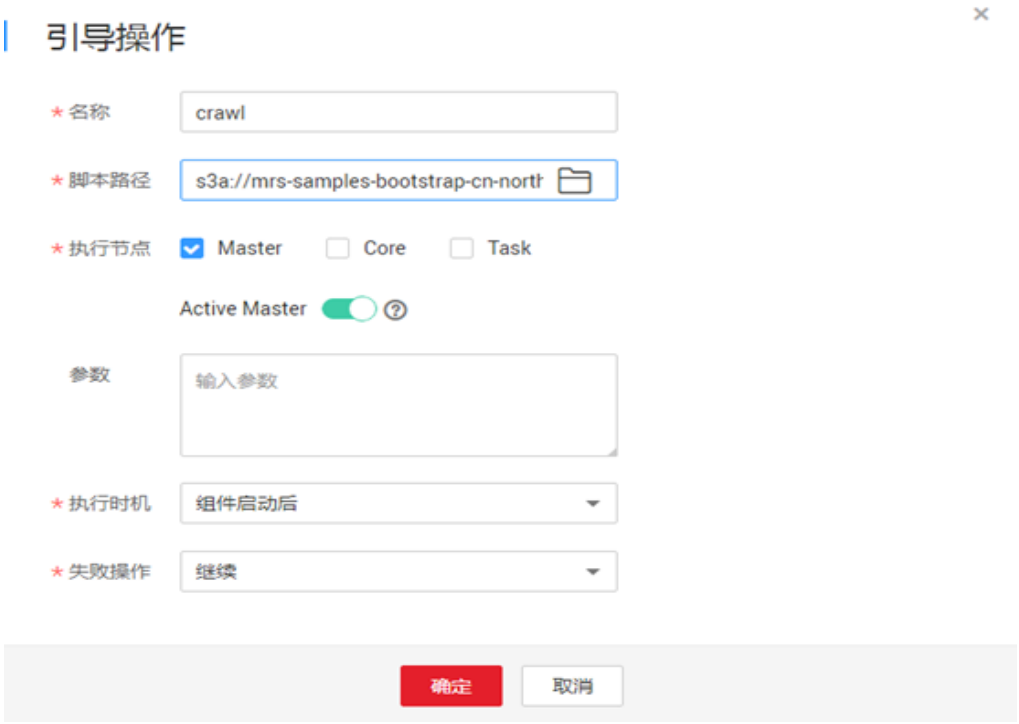

4.1.6 配置后点击“立即购买”进行集群的创建。等到集群创建成功后，点到集群管理界面中可以看到引导操作的完成状态。

4.2 申请弹性 IP

4.2.1 登录虚拟私有云地址，点击左侧“弹性公网 IP”页签，进入弹性公网 IP 页面。点击右上角的“购买弹性公网 IP”进入到申请页面。

4.2.2 在打开的页面中填写弹性 IP 的基本信息：

参数	值
计费模式	按需计费
区域	华北-北京一
类型	默认值：全动态 BGP
带宽类型	默认值：独享带宽
计费方式	按流量收费（只有从华为云出口的流量才计费，例如：上传数据到华为云是不收费的，从华为云下载数据是计费的）
带宽大小	默认值：5 Mbit/s
带宽名称	mrs-demo-stream
标签	默认值：（空）
购买量	1

配置完成后部分信息如图：

4.2.3 单击右下角的“立即购买”，在下一个页面中确认资源详情后，单击“提交”。

4.3 为流式集群绑定弹性 IP

4.3.1 点击 MapReduce 服务进入集群列表页面，在“现有集群”中点击之前创建的 MRS 流式集群的名称，进入到该集群的管理页面。

4.3.2 从节点列表中找到“类型”为“Master1”的节点，点击名称进入到云服务器控制台页面。

4.3.3 然后在下方的菜单栏中点击“弹性 IP”菜单，然后点击“绑定弹性 IP”按钮，绑定之前创建的弹性 IP。

5. 使用 devcloud 编译部署程序

5.1 接收并构建任务

5.1.1 点击 https://devcloud.huaweicloud.com/classroom/joinhomework/4ac91fa71cd1485a8870f1c43903edb8/16c555201360412d9098a48344db266f 进入项目接收界面，点击右侧的“接收项目”按钮，等待接收后进入到实践项目页面中。

5.1.2 然后点击左侧菜单栏中的“构建&发布->编译”页签，然后点击右边的“开始构建”按钮进行构建，可以点击项目名称来查看详细的编译构建过程。

5.2 添加主机授信（已添加过的可跳过该步骤）

5.2.1 点击软件开发云上面的“服务”下拉框，选中“部署”按钮进入到部署页面。然后点击“主机管理”标签，点击右侧的“添加主机”按钮进行配置。

5.2.2 在新打开的页面中填写主机的基本信息，按照以下方式填写：

参数	值
添加方式	默认值：单个添加
主机名	mrs_demo
弹性 IP	填写之前创建的流式集群弹性 IP，如：10.10.10.10
操作系统	默认值：linux
授信方式	密码授信
用户名	root
密码	创建集群时设置的密码

5.3 配置部署任务

5.3.1 点击左上角的“首页”，然后点击项目名称回到实践项目的页面中，点击左侧菜单栏中的“构建&发布->部署”页签，然后点击右边的“新建任务”按钮进行部署任务配置。

5.3.2 选择非模板任务，在新打开的页面中填写部署任务的基本信息，然后点击“确认”进行创建，下表为必填的参数列表：

参数	值
名称	weather_example
部署类型	shell 部署

选择软件包	通过界面选择添加之前构建生成的软件包：weather-crawl-mrs.jar
配置主机	通过界面选择之前配置授信的 IP，如：10.10.10.10
部署路径	/opt/
shell 脚本	在脚本文件的最下方添加以下内容（原内容不能删除） （password 为分析集群 master 节点 root 用户密码，masterIP 为分析集群节点 IP） #初始化需要的参数值 masterIp="masterIp" analysis_password="password" zookeeper_connect_analysis="$masterIp":2181 bootstrap_servers=`grep bootstrap.servers /opt/client/Kafka/kafka/config/producer.properties\|cut -d'=' -f2` rm -rf /opt/conf/ mkdir /opt/conf/ source /opt/client/bigdata_env #下载程序运行需要的依赖包和配置文件 wget https://obs-weather-crawler.obs-website.cn-east-2.myhwclouds.com/jsoup-1.10.3.jar mv jsoup-1.10.3.jar /opt/conf wget https://obs-devcloud.obs.cn-north-1.myhwclouds.com/weather/properties.properties #修改 flume 的配置文件，填入对应的环境参数 sed -i "s/bootstrap_servers/$bootstrap_servers/g" /opt/properties.properties sed -i "s/zookeeper_connect_analysis/$zookeeper_connect_analysis/g" /opt/properties.properties nohup mv properties.properties /opt/Bigdata/MRS/FusionInsight-Flume-1.6.0/flume/conf/ chown omm:wheel /opt/Bigdata/MRS/FusionInsight-Flume-1.6.0/flume/conf/properties.properties cp weather-crawl-mrs.jar /opt/Bigdata/MRS/FusionInsight-Flume-1.6.0/flume/lib/ chown omm:wheel /opt/Bigdata/MRS/FusionInsight-Flume-1.6.0/flume/lib/weather-crawl-mrs.jar chmod 755 /opt/Bigdata/MRS/FusionInsight-Flume-1.6.0/flume/lib/weather-crawl-mrs.jar #拷贝启动程序需要的分析集群的配置文件 check_user=`whoami` echo "$check_user"

```
echo '#!/usr/bin/expect -f'>/opt/mrs.sh
echo "set password $analysis_password">>/opt/mrs.sh
echo "spawn scp -r root@$masterIp:/opt/client/Hive/config/* roo
t@$masterIp:/opt/client/HBase/hbase/conf/* root@$masterIp:/etc/
hosts /opt/conf/">>/opt/mrs.sh
echo 'expect "*password"'>>/opt/mrs.sh
echo 'send "$password\n"'>>/opt/mrs.sh
echo 'expect "*password"'>>/opt/mrs.sh
echo 'send "$password\n"'>>/opt/mrs.sh
echo 'expect "*password"'>>/opt/mrs.sh
echo 'send "$password\n"'>>/opt/mrs.sh
echo 'expect "*password"'>>/opt/mrs.sh
echo 'send "$password\n"'>>/opt/mrs.sh
echo 'interact'>>/opt/mrs.sh
chmod 755 /opt/mrs.sh
./mrs.sh
chown -R omm:wheel /opt/conf/
chmod 755 /opt/conf/*
if [ "`cat /etc/hosts |grep "$masterIp"`" == "" ];then
  cat /opt/conf/hosts |grep node >> /etc/hosts
fi
#启动爬虫程序
nohup java -cp .:weather-crawl-mrs.jar:/opt/conf:/opt/conf/jsoup-
1.10.3.jar:/opt/client/Hive/Beeline/lib/*:/opt/client/HDFS/hadoop/li
b/*:/opt/client/HBase/hbase/lib/*:/opt/client/Kafka/kafka/config:/o
pt/client/Kafka/kafka/libs/* com.huawei.mrs.crawl.WeatherCrawler
 > /opt/log.log 2>&1 &
sleep 10
#使用 omm 用户启动 flume 客户端
echo "exec su omm <<EOF" > /opt/startFlume.sh
echo "sh /opt/Bigdata/MRS/FusionInsight-Flume-1.6.0/flume/bin/f
lume-manage.sh restart" >> /opt/startFlume.sh
echo "EOF" >> /opt/startFlume.sh
chmod 755 startFlume.sh
nohup sh /opt/startFlume.sh
```

>>主机名信息可以在节点信息中查看：

>>最终效果如下图：

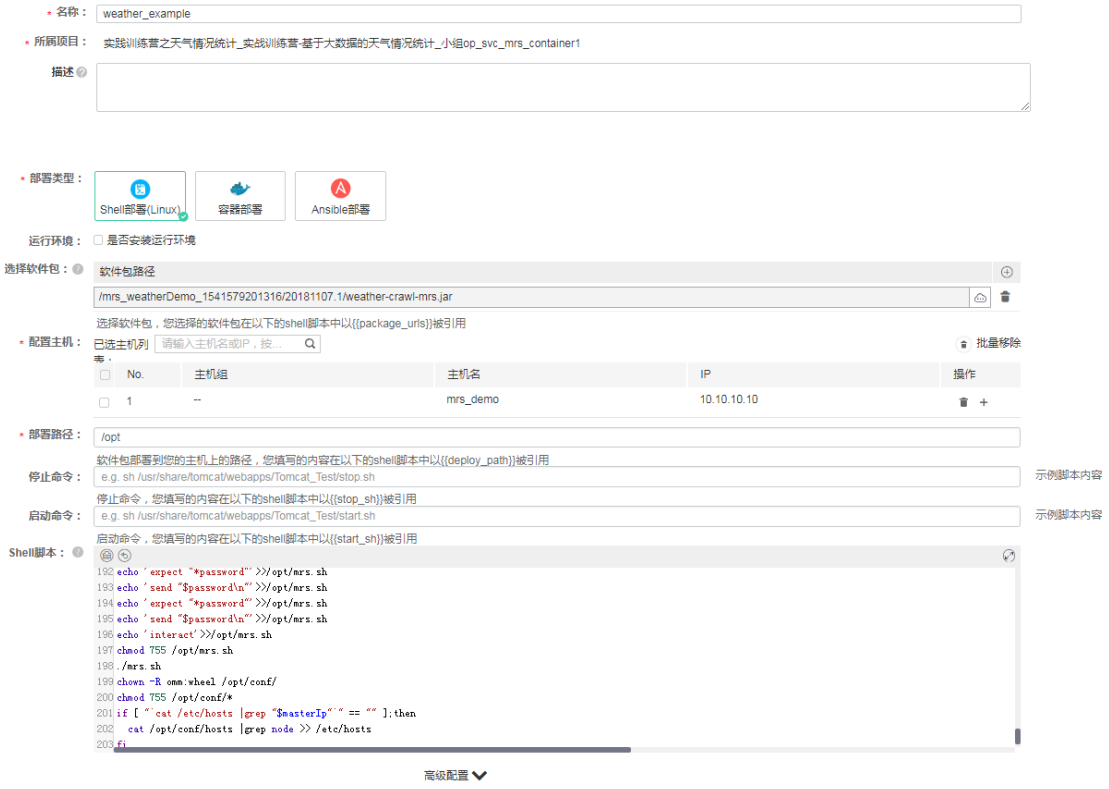

5.4 执行程序并查看结果

5.4.1 进入到部署详情页面，然后点击“一键部署”按钮，即可完成部署。等到部署结束后就可以在界面上看到程序的执行结果，效果如下图：

部署日志 部署历史

```
2 2018-10-09 16:07:57,811 [
3 "到部署路径 /opt/",
4 "传递的url是: ",
5 "软件包备份到文件夹/package_bak/下 ",
6 "下载软件包成功",
7 "Start flume successfully,pid=31160.",
8 "root",
9 "spawn scp -r root@192.168.128.231:/opt/client/Hive/config/* root@192.168.128.231:/opt/client/HBase/hbase/conf/* /opt/conf/",
10 "root@192.168.128.231's password: ",
11 "",
12 "hiveclient.properties                    0%    0     0.0KB/s   --:-- ETA",
13 "hiveclient.properties                  100%  129     0.1KB/s   00:00    ",
14 "",
15 "hivemetastore-site.xml                  0%    0     0.0KB/s   --:-- ETA",
16 "hivemetastore-site.xml                100% 1709     1.7KB/s   00:00    ",
17 "",
18 "hive-site.xml                          0%    0     0.0KB/s   --:-- ETA",
19 "hive-site.xml                         100%  698     0.7KB/s   00:00    ",
20 "root@192.168.128.231's password: ",
21 "",
22 "client.env                             0%    0     0.0KB/s   --:-- ETA",
23 "client.env                            100%   87     0.1KB/s   00:00    ",
24 "",
25 "core-site.xml                          0%    0     0.0KB/s   --:-- ETA",
26 "core-site.xml                         100% 5647     5.5KB/s   00:00    ",
27 "",
28 "gc-opts.sh                            0%    0     0.0KB/s   --:-- ETA",
29 "gc-opts.sh                           100%   17KB  17.1KB/s   00:00    ",
30 "",
31 "hadoop-metrics2-hbase.properties       0%    0     0.0KB/s   --:-- ETA",
32 "hadoop-metrics2-hbase.properties      100% 1811     1.8KB/s   00:00    ",
```

5.4.2 如果想更详细的了解整个过程，可以进行代码修改然后提交到代码仓库，接着只需执行编译和部署的执行按钮就可重新查看结果。也可以通过 putty 等工具连接到 MRS 集群上，通过 MRS 客户端进行其他操作。具体操作手册参考帮助文档：https://support.huaweicloud.com/usermanual-mrs/mrs_01_0081.html

6. 使用 superset 展示数据

6.1 为流式集群添加安全规则

6.1.1 进入 MRS 集群列表，点击之前创建的流式集群名称，进入到集群管理页面。

6.1.2 从节点列表中找到“类型”为“Master1”的节点，点击名称进入到云服务器控制台页面。

6.1.3 点击“安全组"，再点击 ID 进入到安全组设置界面。

6.1.4 选择入方向，点击“添加规则"，在端口范围栏里填上"38088"，点击确定。

6.2 使用 superset

6.2.1 当爬虫程序启动后，可在浏览器输入如下地址登录到 superset 工具中。

http://弹性 IP:38088

6.2.2 账号为：admin，密码为：Admin12!。登录后可在右上角将语言改成中文。

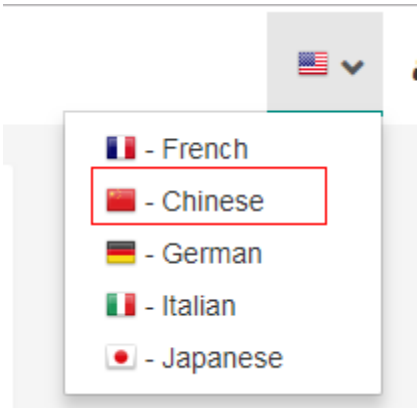

6.2.3 在顶部菜单栏点击“数据源->数据库”，进入到数据页面，点击右上角的“添加新纪录”按钮，进行 Hive 的关联。

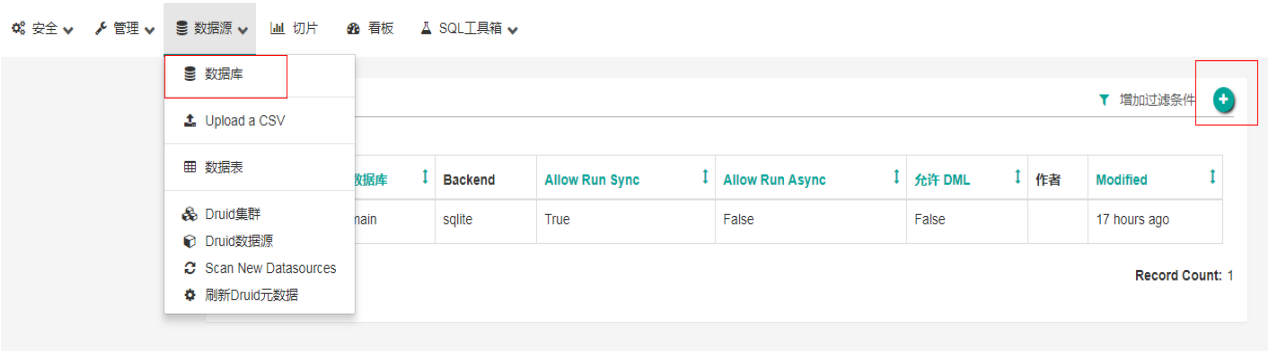

6.2.4 需要修改的配置参数参考下面表格，其余参数保持默认值（masterIP 为分析集群 master 节点 ip）。

参数	值
数据库	hive
SQLAlchemy URI	impala://masterIP(192 开头的 IP):10000/default
扩展	{ "metadata_params": {}, "engine_params": {"connect_args":{"auth_mechanism":"PLAIN","kerberos_service_name":"hive"}} }
在 SQL 工具箱中公开	勾选

添加数据库

数据库	hive
SQLAlchemy URI	impala://192.168.0.243:10000/default Refer to the SqlAlchemy docs for more information on how to structure your URI. 测试连接
缓存时间	缓存时间
扩展	{ "metadata_params": {}, "engine_params": {"connect_args":{"auth_mechanism":"PLAIN","kerberos_service_name":"hive"}} } JSON string containing extra configuration elements. The `engine_params` object gets unpacked into the sqlalchemy.create_engine call, while the `metadata_params` gets unpacked into the sqlalchemy.MetaData call.
在SQL工具箱中公开	☑ 在SQL工具箱中公开这个数据库
Allow Run Sync	☑ 允许用户运行同步查询，这是默认值，可以很好地处理在web请求范围内执行的查询(<~1分钟)

配置完成后点击“测试连接”按钮，当显示“Seems OK!”代表连接成功，然后点击“保存”。

6.2.5 点击上方的“SQL 工具箱->SQL 编辑器”，然后在左侧选择相应数据库和表。选择后有报错可忽略。

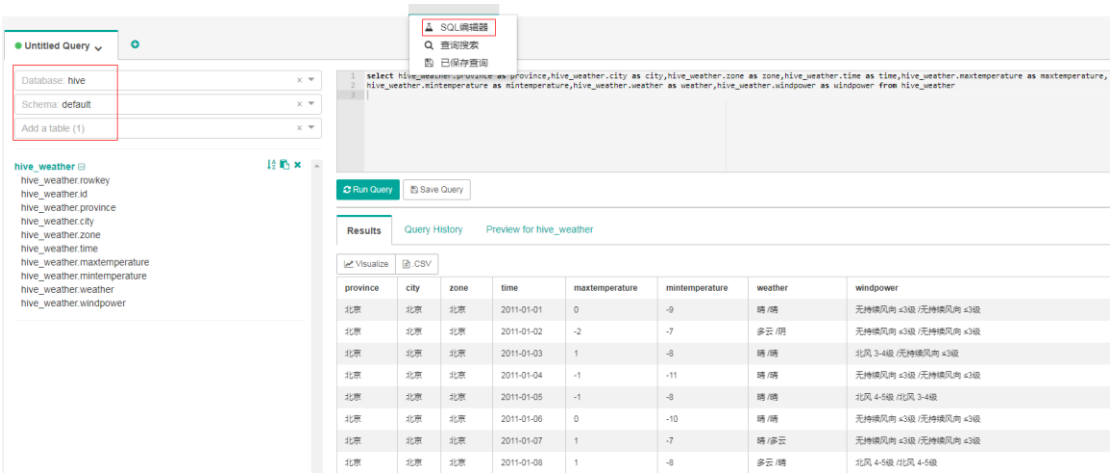

6.2.6 接着输入如下的 SQL 语句进行查询：

```
select hive_weather.province as province,hive_weather.city as city,hive_weather.zone as zone,hive_weather.time as time,hive_weather.maxtemperature as maxtemperature,
hive_weather.mintemperature as mintemperature,hive_weather.weather as weather,hive_weather.windpower as windpower from hive_weather
```

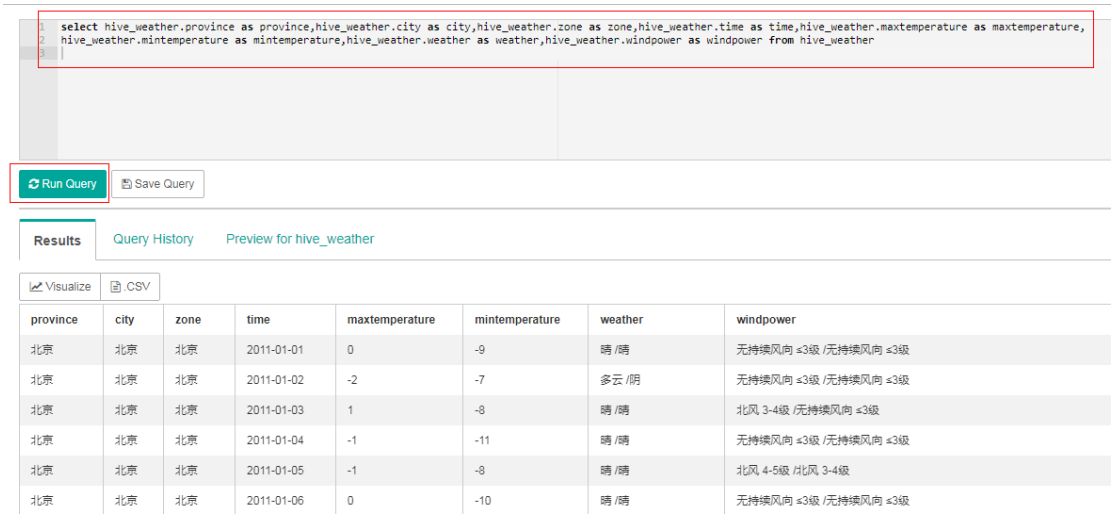

province	city	zone	time	maxtemperature	mintemperature	weather	windpower
北京	北京	北京	2011-01-01	0	-9	晴 /晴	无持续风向 ≤3级 /无持续风向 ≤3级
北京	北京	北京	2011-01-02	-2	-7	多云 /阴	无持续风向 ≤3级 /无持续风向 ≤3级
北京	北京	北京	2011-01-03	1	-8	晴 /晴	北风 3-4级 /无持续风向 ≤3级
北京	北京	北京	2011-01-04	-1	-11	晴 /晴	无持续风向 ≤3级 /无持续风向 ≤3级
北京	北京	北京	2011-01-05	-1	-8	晴 /晴	北风 4-5级 /北风 3-4级
北京	北京	北京	2011-01-06	0	-10	晴 /晴	无持续风向 ≤3级 /无持续风向 ≤3级

6.2.7 然后点击“Visualize”按钮按照下图方式进行配置。然后点击“Visualize”按钮，等待两分钟，会出现最终的柱状图结果，此时显示的结果是整个北京的总温度。

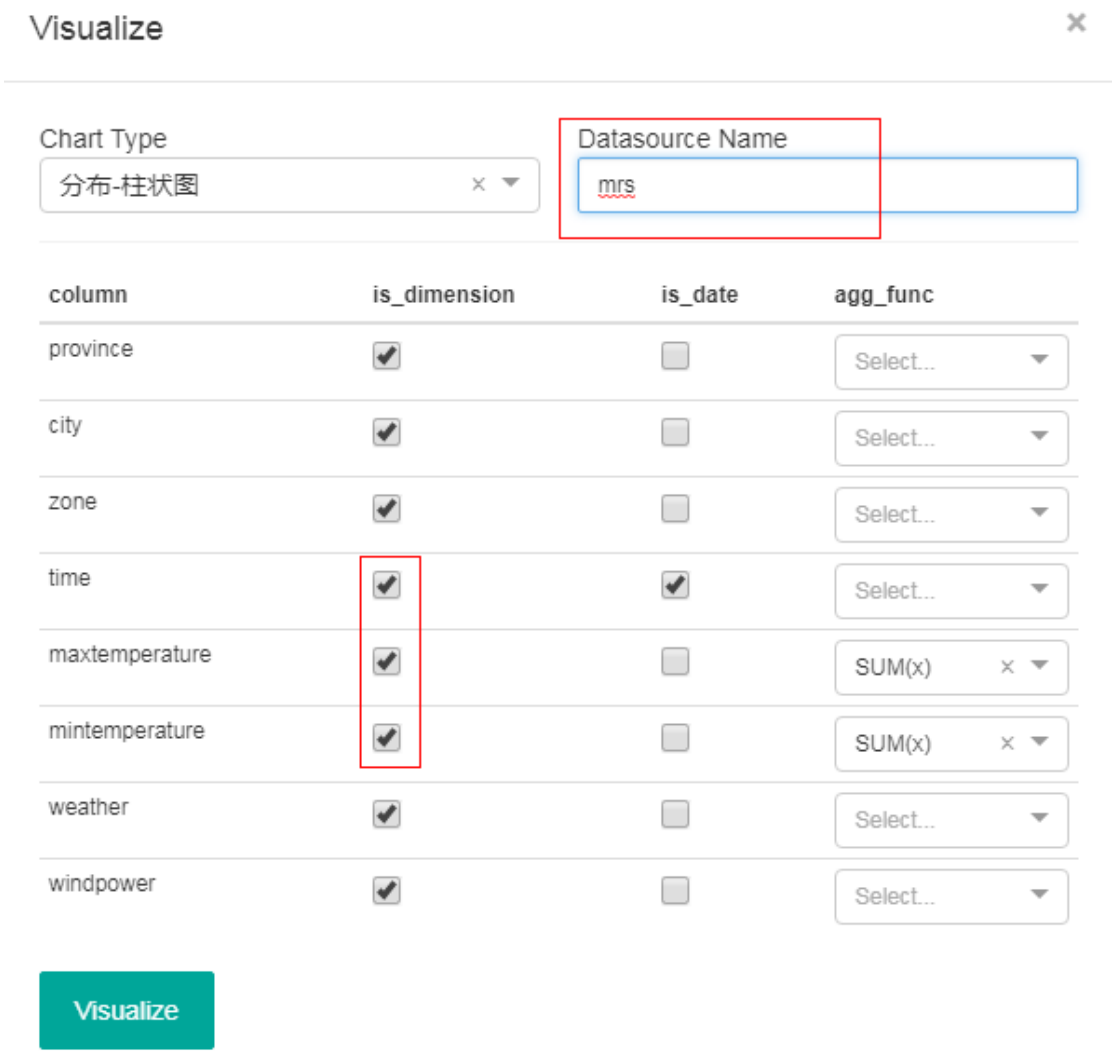

6.2.8 接下来就可以根据自己的要求进行数据调整和展示。比如做一个北京地区的历史最高温度曲线图，可以参考如下配置：

参数	值
图表类型	时间序列-折线图
Time-since	7 years ago
Group by	清空
筛选	1. 选择“zone” 2. 选择“==” 3. 填入“北京”

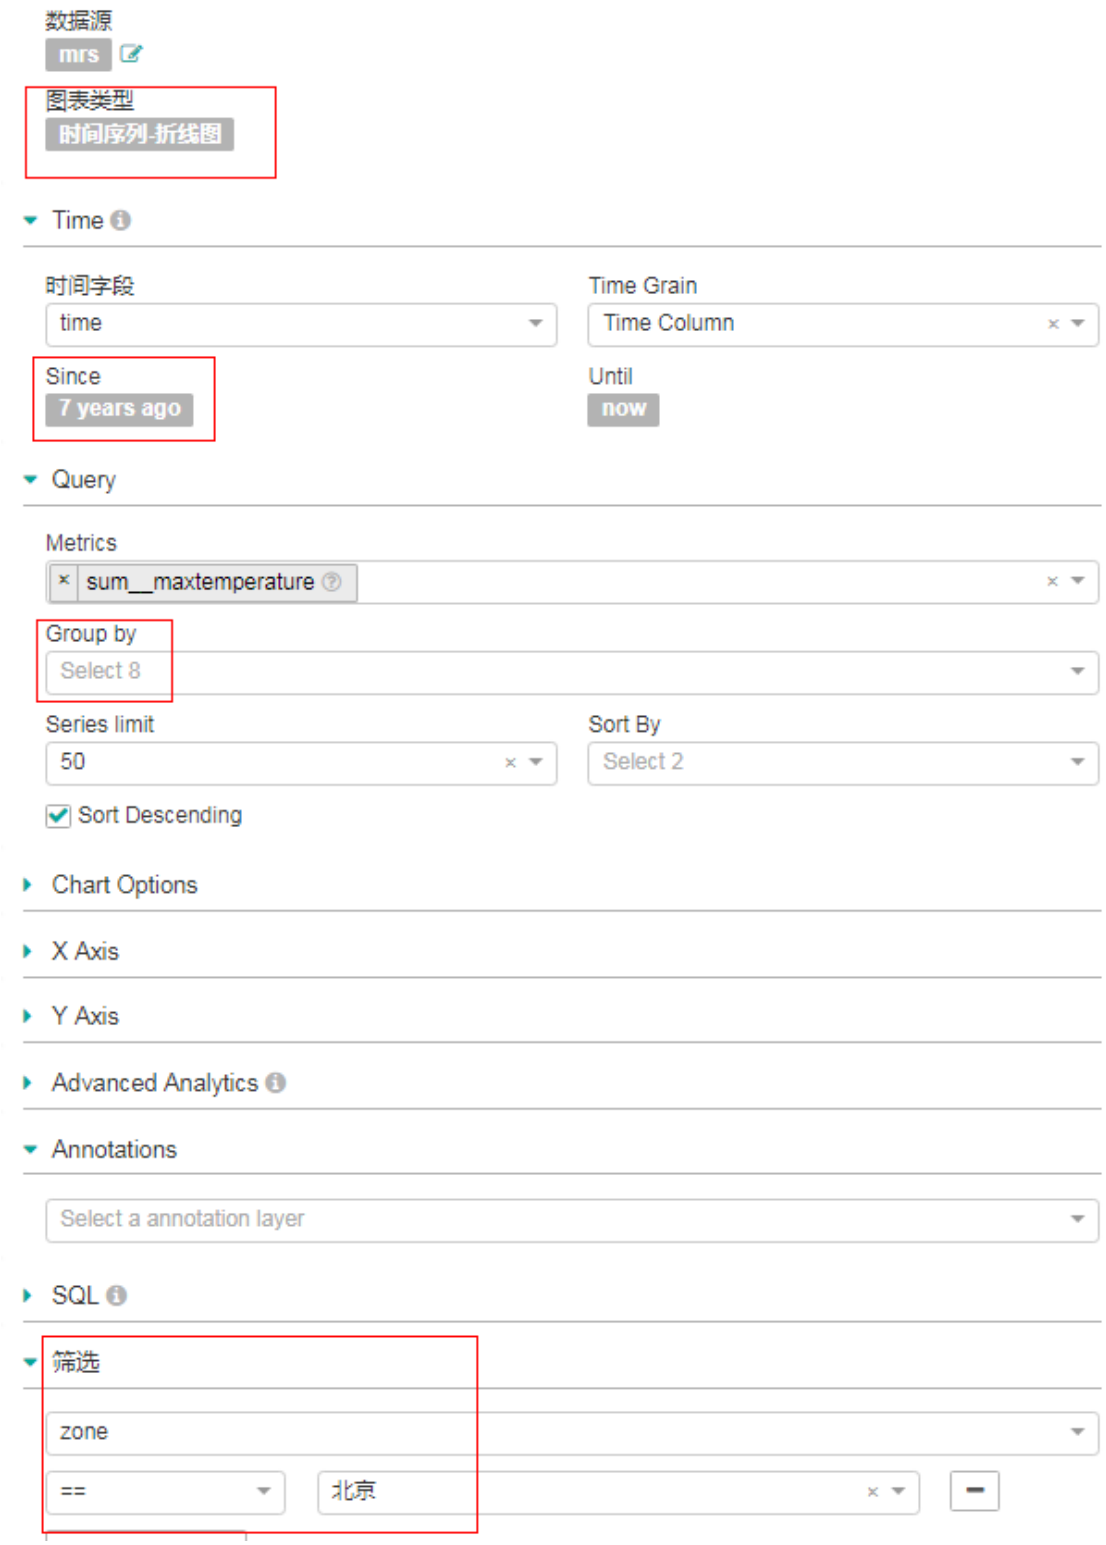

6.2.9 点击上方的“Run Query”按钮，如果当前有在跑的任务，先点击“stop”按钮，再点击“Run Query”按钮。

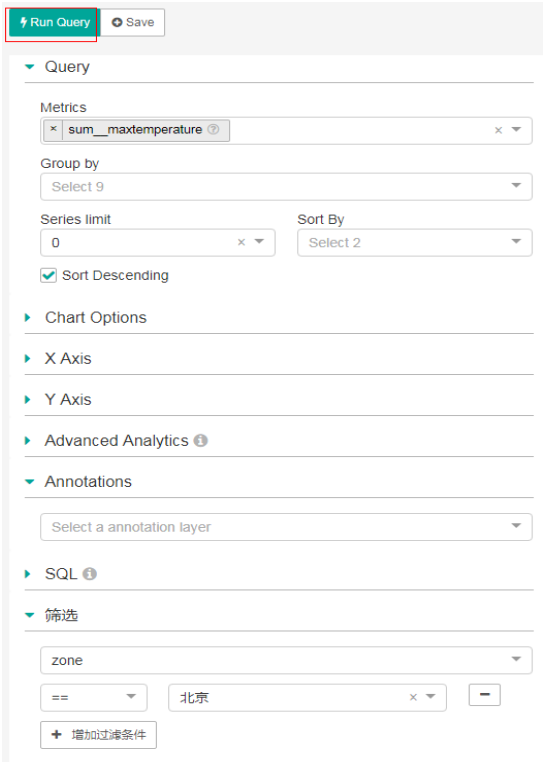

6.2.10 最终结果如图：

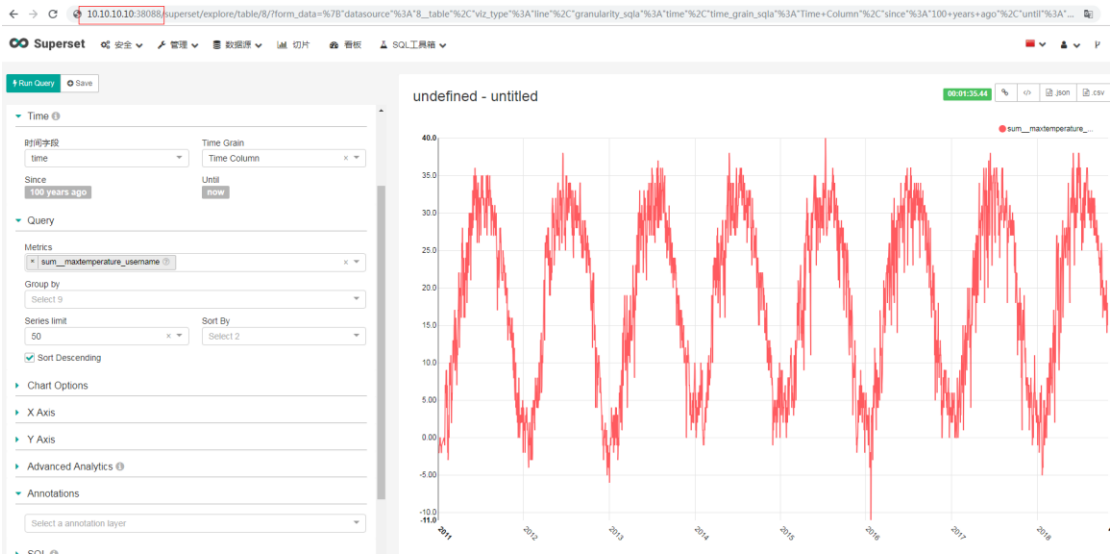

Superset 更详细的使用指导请参考：https://bbs.huaweicloud.com/forum/thread-12604-1-1.html

7. 打卡任务

完成步骤6.2.10，将最终结果截图并在打卡程序附上superset网站的地址。待第二天验收完成前不要清理集群和弹性IP资源。清理资源会统一发送消息通知。

8. 附录

未释放的集群资源也可用于附加题的操作部署或者练习前一期大数据实践训练营的内容。

第一期大数据实践训练营包含了HDFS、HBase、Hive、Spark、Mapreduce、kafka、flume、storm等主流大数据组件的练习，不仅有客户端使用练习，还有二次开发的练习，前一期活动地址：

https://bbs.huaweicloud.com/forum/forum.php?mod=viewthread&tid=8940&page=1#pid27501

操作手册地址：https://obs-devcloud.obs-website.cn-north-1.myhwclouds.com/